Tugas Machine Learning Pertemuan 6
Semester Ganjil T.A. 2026/2027

Pengerjaan:

1. Tugas ini dapat dikerjakan dalam kelompok beranggotakan 1 – 3 orang.
2. Soal nomor 2 s.d. 4 dikerjakan menggunakan bahasa pemrograman Python.
3. *Output* yang dikumpulkan:
   a. *File coding* Python (dalam format .py atau .ipynb, boleh dikumpulkan dalam bentuk *link repository*/GitHub)
   b. *File* laporan (dalam format .docx atau .pdf)
4. Untuk metode klasifikasi dan *clustering* yang digunakan, tidak boleh ada > 1 kelompok yang menggunakan kombinasi algoritma dan parameter yang persis sama
5. Kumpulkan *file coding* dan laporan melalui email ke alamat isnan.mulia@ibik.ac.id, menggunakan *subject* "[Tugas P6 Machine Learning 2026/2027]". Pengumpulan cukup diwakili oleh salah satu anggota kelompok, dan di-*cc*-kan kepada seluruh anggota kelompok.
6. Pengumpulan tugas ditunggu sampai dengan tanggal **14 November 2026**. Lewat dari tanggal tersebut, tugas tidak diterima.

Terdapat sebuah *file* CSV yang berisi dataset penyakit gagal jantung, yang dapat diakses pada link **https://t2m.io/LaN8isBe**. Dataset ini mengandung 11 atribut prediktor, dan 1 atribut label dengan nama HeartDisease. Dataset sudah dimodifikasi, sehingga mengandung *missing values*. Gambar di bawah menunjukkan beberapa baris dari dataset tersebut.

Age	Sex	ChestPainType	RestingBP	Cholesterol	FastingBS	RestingECG	MaxHR	ExerciseAngina	Oldpeak	ST_Slope	HeartDisease
44	M	ASY	120	169	0	Normal	144	Y	2,8	Down	1
63	M	ASY	140	187	0	LVH		Y	4	Up	1
63	F	ASY	124	197	0	Normal	136	Y	0	Flat	1
41	M	ATA	120	157	0	Normal	182	N	0	Up	0
59	M	ASY	164		1	LVH	90	N	1	Flat	1
57	F	ASY	140	241	0	Normal	123	Y	0,2	Flat	1
45	M	TA	110	264	0	Normal	132	N	1,2	Flat	1
68	M	ASY	144	193	1	Normal	141	N	3,4	Flat	1
57	M	ASY		131	0	Normal	115	Y	1,2	Flat	1
57	F	ATA		236	0	LVH	174	N	0	Flat	1
38	M	NAP	138	175	0	Normal	173	N	0	Up	0

Anda diminta untuk:

1. [15 poin] Mengidentifikasi nama dan jenis atribut dari seluruh atribut prediktor dan atribut label yang terdapat pada dataset tersebut. Sebelum menentukan jenis atribut, Anda dapat memeriksa terlebih dahulu berapa banyak nilai unik yang terdapat di setiap atribut. Untuk atribut berjenis kategorik, sebutkan nilai unik yang terdapat pada atribut tersebut.

2. [20 poin] Melakukan praproses data. Detail untuk pengerjaan praproses data adalah sebagai berikut.
   a. Pisahkan bagian atribut prediktor dengan label data menjadi dua variabel terpisah

b. Gunakan SimpleImputer untuk menangani *missing values*, dengan nilai rata-rata dari atribut data sebagai strategi pengisian nilai
c. Terapkan StandardScaler untuk mengubah nilai atribut prediktor berjenis numerik
d. Terapkan praproses data tambahan, jika dibutuhkan
e. Tampilkan statistik deskriptif dari atribut data sebelum dan setelah dilakukan praproses data

3. [20 poin] Membangun model klasifikasi berdasarkan dataset yang telah dilakukan praproses data. Detail untuk pengerjaan klasifikasi adalah sebagai berikut.
   a. Gunakan algoritma pengklasifikasi apapun untuk membangun model klasifikasi. Parameter yang digunakan boleh disesuaikan dengan bebas
   b. Gunakan metode *holdout* untuk membagi keseluruhan dataset menjadi data *training* dan data *testing*, dengan proporsi 85% data *training* dan 15% data *testing*
   c. Tampilkan *confusion matrix* dan akurasi dari model klasifikasi. Metrik evaluasi lainnya dapat ditambahkan juga, jika dibutuhkan

4. [20 poin] Membangun model *clustering* berdasarkan dataset yang telah dilakukan praproses data. Detail untuk pengerjaan *clustering* adalah sebagai berikut.
   a. Gunakan algoritma *clustering* apapun untuk melakukan *clustering*. Parameter yang digunakan boleh disesuaikan dengan bebas
   b. Tampilkan SSE dan *silhouette score* dari model *clustering*. Metrik evaluasi lainnya dapat ditambahkan juga, jika dibutuhkan

5. [25 poin] Merangkum apa saja yang dilakukan pada poin 1 s.d. 4 di atas dalam bentuk laporan tertulis. Detail yang harus dituliskan adalah sebagai berikut.
   a. Pembahasan mengenai nama dan jenis atribut dari setiap atribut prediktor dan atribut label yang terdapat pada dataset
   b. Pembahasan mengenai statistik deskriptif dari data, sebelum dan setelah dilakukan praproses data. Jika ada tambahan praproses data yang dilakukan, berikan penjelasannya
   c. Pembahasan mengenai model klasifikasi
   d. Pembahasan mengenai model *clustering*
   e. Lengkapi laporan dengan nama dan NPM setiap anggota, serta kelas